

SVEUČILIŠTE JURJA DOBRILE U PULI
FAKULTET INFORMATIKE

Tin Pritišanac

Analiza tržišta automobila 1970.-2024.

SEMINARSKI RAD

Pula, rujan, 2025. godine

SVEUČILIŠTE JURJA DOBRILE U PULI
FAKULTET INFORMATIKE

Tin Pritišanac

Analiza tržišta automobila 1970.-2024.

SEMINARSKI RAD

JMBAG: 0171256219, izvanredni student
Studijski smjer: Informatika
Kolegij: Skladišta i rudarenje podataka
Mentor: doc.dr.sc. Goran Oreški

Pula, rujan, 2025. godine



IZJAVA O AKADEMSKOJ ČESTITOSTI

Ja, dolje potpisani Pritišanac Tin, ovime izjavljujem da je ovaj seminarski rad rezultat isključivo mogega vlastitog rada, da se temelji na mojim istraživanjima te da se oslanja na objavljenu literaturu kao što to pokazuju korištene bilješke i bibliografija. Izjavljujem da niti jedan dio Završnog rada nije napisan na nedozvoljen način, odnosno da je prepisan iz kojega necitiranog rada, te da ikoji dio rada krši bilo čija autorska prava. Izjavljujem, također, da nijedan dio rada nije iskorišten za koji drugi rad pri bilo kojoj drugoj visokoškolskoj, znanstvenoj ili radnoj ustanovi.

Student

U Puli, rujan, 2025. godine

Sadržaj

1	Uvod	1
2	Projektni zadatak	2
2.1	Definicija problema i motivacija	2
2.2	Cilj i opis projektnog zadatka	2
2.3	Opseg i ograničenja projekta	2
2.4	Očekivani rezultati i doprinosi	3
2.5	Metodologija rada	3
3	Odabir i analiza skupa podataka	5
3.1	Izvor i kriteriji odabira podataka	5
3.2	Eksploratorna analiza podataka	5
3.2.1	Osnovna struktura podataka	5
3.2.2	Ključni uvidi iz eksploratorne analize	6
3.3	Priprema i obrada podataka	7
3.3.1	Čišćenje i standardizacija podataka	7
3.3.2	Proširenje skupa podataka hijerarhijskim atributima	8
3.3.3	Podjela skupa podataka za simulaciju različitih izvora	9
3.4	Rezultati pripreme podataka	10
4	Relacijski model podataka	11
4.1	Analiza entiteta i atributa	11
4.2	Konceptualni model podataka	11
4.3	Implementacija relacijskog modela	12
4.4	Automatizacija kreiranja i popunjavanja baze	13
4.5	Validacija podataka i testiranje	14
5	Dimenzijski model podataka	16
5.1	Konceptualni pristup dimenzijskom modeliranju	16
5.2	Arhitektura zvjezdastog modela	16
5.3	Tablica činjenica - Fact_Car_Sales	18
5.4	Dimenzijske tablice i SCD strategije	18
5.5	Prednosti zvjezdastog modela	20
5.6	Implementacijski detalji	20
6	ETL proces	22
6.1	Arhitektura ETL pipelinea	22
6.2	Extract faza - izvlačenje podataka	23
6.3	Transform faza - transformacija podataka	23
6.3.1	Transformacija dimenzijskih tablica	24
6.3.2	Transformacija tablice činjenica	25
6.4	Load faza - učitavanje u skladište podataka	26
6.5	Orkestracija i monitoring	28
6.6	Prednosti implementiranog ETL rješenja	28

7	OLAP analiza	30
7.1	Osnove OLAP tehnologija	30
7.2	Tableau kao OLAP alat	30
7.3	Analiza cijena kroz dimenzije	31
7.3.1	Regionalna analiza cijena	31
7.3.2	Analiza po zemljama proizvođača	32
7.3.3	Vremenska analiza cijena	32
7.4	Analiza proizvođača i modela	33
7.4.1	Top modeli po cijeni	33
7.4.2	Odnos cijene i veličine motora	34
7.4.3	Analiza po tipu motora	35
7.4.4	Detaljna analiza po modelu	37
7.5	Analiza eksploatacijskih karakteristika	38
7.5.1	Odnos starosti i kilometraže	38
7.5.2	Kilometraža po tipu motora	39
7.6	Tržišna analiza i trendovi	40
7.6.1	Udio proizvođača na tržištu	40
7.6.2	Geografska distribucija tipova mjenjača	41
7.7	Distribucijska analiza	43
7.7.1	Distribucija cijena	43
7.7.2	Distribucija kilometraže	43
7.7.3	Usporedba distribucije po tipu prijenosa	44
7.8	Analiza efikasnosti i performansi	46
7.8.1	Potrošnja goriva prema starosti	46
7.9	Fiskalna analiza	47
7.9.1	Odnos cijene i poreza po regijama	47
7.9.2	Porez kao postotak cijene	48
7.9.3	Prosječni porez po zemljama proizvođača	49
7.10	Kombinirana analiza dimenzija	50
7.10.1	Multi-dimenzijska analiza starosti	50
8	Zaključak	52
	Literatura	54
	Popis slika	56
	Popis tablica	57

1 Uvod

U današnjem digitalno vođenom poslovnom okruženju, sposobnost efikasnog prikupljanja, obrade i analize velikih količina podataka postala je ključni čimbenik uspjeha za organizacije u gotovo svim industrijskim granama. Automobilska industrija, kao jedna od najkompleksnijih i najkonkurentnijih grana gospodarstva, posebno se oslanja na napredne tehnologije skladištenja i analize podataka kako bi razumjela tržišne trendove, potrebe kupaca i operacijske učinkovitosti [1].

Skladišta podataka (eng. *data warehouses*) predstavljaju temelj modernih sustava za podršku odlučivanju, omogućujući integraciju različitih izvora podataka u jedinstvenu, koherentnu strukturu optimiziranu za analitičke potrebe [2]. U kontekstu automobilske industrije, ovakvi sustavi omogućuju analizu složenih odnosa između cijena vozila, karakteristika proizvođača, tržišnih segmenata i regionalnih specifičnosti.

Ovaj rad predstavlja sveobuhvatan pristup razvoju sustava za skladištenje i rudarenje podataka primjenjenog na analizu automobilske tržišta. Kroz razvoj kompletnog ETL (Extract, Transform, Load) procesa, projekt demonstrira transformaciju sirovih podataka o automobilima u strukturirani dimenzijski model prilagođen OLAP (Online Analytical Processing) analizama. Korištenjem skupa podataka koji sadrži preko 97.000 zapisa o vozilima različitih proizvođača, modela i karakteristika, razvijen je sustav koji omogućuje dubinsku analizu tržišnih trendova i poslovnih uvida.

Glavni cilj ovog projekta je ilustracija praktične primjene teorijskih koncepata skladišta podataka kroz razvoj funkcionalnog sustava koji može poslužiti organizacijama poput autoklubova, analitičkih kuća ili samim proizvođačima automobila u donošenju informiranih poslovnih odluka [3]. Projekt obuhvaća sve ključne faze razvoja sustava - od eksploratorne analize početnih podataka, preko dizajna relacijskog i dimenzijskog modela, do implementacije ETL procesa i prijedloga OLAP analiza.

Struktura rada prati logični tijek razvoja sustava, počevši od analize i pripreme početnog skupa podataka, preko stvaranja normaliziranog relacijskog modela, do konačne implementacije zvjezdastog modela optimiziranog za analitičke potrebe. Svaki korak popraćen je detaljnim objašnjenjima projektnih odluka i praktičnih implementacijskih izazova, čineći ovaj rad korisnim resursom za razumijevanje kompleksnosti razvoja realnih sustava za skladištenje podataka.

Kroz ovaj projekt, nastoji se pokazati kako tehnologije poput Apache Spark-a, MySQL-a i Tableau-a mogu biti integrirane u koherentan sustav koji omogućuje ne samo tehnički ispravan rad, već i stvaranje dodane vrijednosti kroz kvalitetne poslovne uvide [4].

2 Projektni zadatak

2.1 Definicija problema i motivacija

Automobilska industrija je jedna od najkompleksnijih gospodarskih grana koja generira ogromne količine podataka - od osnovnih karakteristika vozila, preko cijena i tržišnih trendova, do regionalnih specifičnosti i preferencija kupaca. Organizacije koje se bave analizom automobilskeg tržišta, poput autoklubova, analitičkih kuća ili samih proizvođača, suočavaju se s izazovom pretvaranja ovih velikih količina podataka u korisne poslovne uvide.

Tradicionalni pristup analize podataka korištenjem jednostavnih baza podataka i osnovnih alata za izvještavanje često se pokazuje neadekvatnim za složene analitičke potrebe. Potreba za dubinskim analizama tržišnih trendova, usporednim analizama proizvođača, segmentacijom kupaca i predviđanjem buduće dinamike tržišta zahtijeva sofisticiraniji pristup [1].

Upravo tu se prepoznaje potreba za razvojem naprednog sustava skladištenja i analize podataka koji će omogućiti organizacijama da iz sirovih podataka izvuku maksimalnu vrijednost te donose informirane strateške odluke.

2.2 Cilj i opis projektnog zadatka

Glavni cilj ovog projekta je razvoj potpunog sustava za skladištenje i rudarenje podataka prilagođenog analizi automobilskeg tržišta. Projekt obuhvaća kompletan tijek rada - od početnih sirovih podataka do konačnih analitičkih izvještaja koji mogu koristiti stvarnim organizacijama u njihovom poslovanju.

Konkretno, projekt ima za cilj:

- **Dizajnirati i implementirati relacijski model podataka** koji odgovara strukturi realnih podataka o automobilima, uključujući sve važne entitete i njihove međusobne odnose
- **Razviti dimenzijski model (star schema)** optimiziran za OLAP analize, koji omogućuje efikasno izvršavanje složenih analitičkih upita
- **Implementirati ETL proces** koji transformira podatke iz relacijske strukture u dimenzijski model koristeći suvremene tehnologije poput Apache Spark-a
- **Kreirati sustav za OLAP analize** koji demonstrira praktičnu primjenu različitih analitičkih operacija (slice, dice, drill-down, roll-up, pivot)
- **Pokazati poslovnu vrijednost** kroz konkretne scenarije korištenja koji ilustriraju kako ovakav sustav može koristiti organizacijama u donošenju poslovnih odluka

2.3 Opseg i ograničenja projekta

Projekt se fokusira na analizu podataka o automobilima prodavanima na fiktivnom tržištu, koristeći skup od preko 97.000 zapisa koji obuhvaća vozila različitih

proizvođača, modela i karakteristika. Ovaj skup podataka pruža reprezentativan uzorak koji omogućuje demonstraciju svih ključnih koncepata skladišta podataka.

Vremenski okvir podataka pokriva razdoblje od 1970. do 2024. godine, s naglaskom na zadnja dva desetljeća, što omogućuje analizu dugoročnih trendova i promjena na tržištu. Podaci uključuju ključne attribute poput cijene, godine proizvodnje, kilometraže, vrste goriva, veličine motora i drugih karakteristika relevantnih za tržišnu analizu.

Projekt se ograničava na demonstraciju tehničkih mogućnosti i metodologija, a ne pretendira na potpunu komercijalnu implementaciju. Fokus je na edukacijskim aspektima i ilustraciji najboljih praksi u razvoju sustava za skladištenje podataka.

2.4 Očekivani rezultati i doprinosi

Na završetku projekta očekuje se sljedeće:

1. **Funkcionalno skladište podataka** s implementiranim relacijskim i dimenzijskim modelom podataka
2. **Potpuno funkcionalan ETL proces** koji automatizira transformaciju podataka između različitih modela
3. **Demonstracija OLAP mogućnosti** kroz konkretne analitičke scenarije i upite
4. **Dokumentacija procesa** koja može služiti kao vodič za buduće slične projekte
5. **Praktični uvidi u tržište automobila** koji ilustriraju poslovnu vrijednost analitičkih sustava

Ovaj projekt predstavlja praktičnu demonstraciju kako teorijski koncepti skladišta podataka i business intelligence mogu biti primijenjeni u realnom kontekstu, pružajući studentima i praktičarima vrijedan uvid u izazove i mogućnosti moderne analize podataka [2].

2.5 Metodologija rada

Projekt slijedi strukturiran pristup razvoja sustava za skladištenje podataka, koji se može podijeliti u pet glavnih faza:

1. **Eksploratorna analiza podataka** - detaljno istraživanje početnog skupa podataka radi razumijevanja strukture, kvalitete i potencijalnih izazova
2. **Dizajn relacijskog modela** - stvaranje normalizirane strukture podataka koja odražava realne poslovne entitete i njihove odnose
3. **Implementacija dimenzijskog modela** - razvoj star schema arhitekture optimizirane za analitičke potrebe

4. **ETL proces** - implementacija sustava za ekstrahiranje, transformaciju i učitavanje podataka koristeći Apache Spark
5. **OLAP analize** - demonstracija analitičkih mogućnosti kroz praktične scenarije kreiranja grafova i tablica u programu Tableau

Svaka faza dokumentirana je s objašnjenjima projektnih odluka, tehničkih izazova i načina njihova rješavanja, čineći projekt korisnim resursom za razumijevanje praktičnih aspekata razvoja sustava za skladištenje podataka.

3 Odabir i analiza skupa podataka

3.1 Izvor i kriteriji odabira podataka

Za potrebe ovog projekta odabran je javno dostupan skup podataka s Kaggle platforme pod nazivom "90,000+ Cars Data From 1970 to 2024" [5]. Ovaj dataset sadrži informacije o preko 97.000 automobila u razdoblju od 1970. do 2024. godine, što ga čini izvrsnim kandidatom za demonstraciju koncepata skladišta podataka i analitičkih sustava.

Kriteriji koji su vodili odabir ovog specifičnog skupa podataka uključuju:

- **Veličina i kompleksnost** - Dataset s preko 97.000 zapisa omogućuje demonstraciju tehnika rukovanja velikim količinama podataka karakterističnih za stvarne poslovne scenarije
- **Bogatstvo atributa** - Podatak sadrži 10 različitih atributa koji pokrivaju ključne aspekte automobilske tržišta: model, godinu proizvodnje, cijenu, vrstu mjenjača, kilometražu, tip goriva, porez, potrošnju, veličinu motora i proizvođača
- **Vremenski raspon** - Podaci se protežu kroz razdoblje od više desetljeća, što omogućuje analizu dugoročnih trendova i temporalnih promjena na tržištu
- **Praktična relevantnost** - Automobilska industrija predstavlja kompleksan sektor s jasnima hijerarhijama (proizvođač → model) i različitim kategorijama koje se prirodno mapiraju na dimenzijske modele podataka
- **Dostupnost i licenca** - Dataset je javno dostupan pod MIT licencom, što omogućuje slobodno korištenje u edukacijske svrhe

Odabrani dataset pruža solidan temelj za ilustraciju ključnih koncepata poslovne inteligencije i skladišta podataka, uključujući normalizaciju, denormalizaciju, ETL procese i OLAP analize.

3.2 Eksploratorna analiza podataka

Prije bilo kakve obrade ili transformacije podataka, provedena je detaljna eksploratorna analiza podataka (EDA) [6]. Ovaj korak je kritičan jer omogućuje razumijevanje strukture, kvalitete i karakteristika skupa podataka, što je neophodno za donošenje informiranih odluka o daljnjem pristupu [7].

3.2.1 Osnovna struktura podataka

Početni dataset sadrži sljedeće atribute:

Atribut	Tip podatka	Opis
model	string	Model automobila
year	integer	Godina proizvodnje
price	integer	Cijena u britanskim funtama
transmission	string	Tip mjenjača (Manual, Automatic, Semi-Auto)
mileage	integer	Kilometraža vozila
fuelType	string	Tip goriva (Petrol, Diesel, Hybrid, Electric)
tax	integer	Godišnji porez
mpg	float	Milje po galonu (potrošnja)
engineSize	float	Veličina motora u litrima
Manufacturer	string	Proizvođač automobila

Tablica 1: Struktura originalnog skupa podataka

Analiza je provedena koristeći Python biblioteke pandas i numpy, kako je prikazano u sljedećem kodu:

Listing 1: Segment skripte za analizu - osnovni pregled strukture podataka

```

1 import pandas as pd
2
3 # Ucitavanje podataka iz CSV datoteke
4 PATH = "../data/cars_data_original.csv"
5 data = pd.read_csv(PATH, delimiter=',')
6
7 # Ispis osnovnih informacija o skupu podataka
8 print("Dimenzije skupa podataka:", data.shape)
9 print("Tipovi podataka:")
10 print(data.dtypes)
11 print("Nedostaju vrijednosti:")
12 print(data.isna().sum())
13 print("Broj jedinstvenih vrijednosti po stupcima:")
14 print(data.nunique())
15 ...

```

3.2.2 Ključni uvidi iz eksploratorne analize

Analiza je otkrila nekoliko važnih karakteristika skupa podataka:

1. **Kvaliteta podataka** - Dataset ne sadrži nedostajuće vrijednosti (null values), što značajno pojednostavljuje faze čišćenja i pripreme podataka
2. **Problematične vrijednosti** - Identificirano je 268 automobila s veličinom motora od 0.0 litara, što upućuje na greške u podacima ili specifične kategorije vozila (električni automobili) koje zahtijevaju posebnu obradu
3. **Distribucija proizvođača** - Analiza je pokazala prisutnost 9 glavnih proizvođača: Ford, Volkswagen, BMW, Skoda, Toyota, Mercedes-Benz (označen kao "merc"), Vauxhall, Audi i Hyundai (označen kao "hyundi")

4. **Vremenski raspon** - Podaci pokrivaju godine od 1970. do 2024., s najvećom koncentracijom vozila iz 2010-ih godina
5. **Cijenski raspon** - Cijene se kreću od nekoliko stotina do preko 100.000 funti, što reflektira širokospan spektar od budget do luksuznih vozila

3.3 Priprema i obrada podataka

Na temelju uvida dobivenih iz eksploratorne analize, implementiran je proces pripreme podataka koji obuhvaća čišćenje, standardizaciju i proširenje originalnog skupa podataka. Ovaj proces je ključan za stvaranje kvalitetne osnove za kasnije faze razvoja skladišta podataka [8].

3.3.1 Čišćenje i standardizacija podataka

Prvi korak u pripremi podataka bio je proces čišćenja i standardizacije, implementiran u sljedećem kodu:

Listing 2: Čišćenje i standardizacija podataka

```
1 import pandas as pd
2
3 # Ucitavanje originalnog skupa podataka
4 df = pd.read_csv("data/cars_data_original.csv", delimiter=',',
5                 ',')
6
7 # Uklanjanje whitespace znakova iz naziva stupaca i podataka
8 df.columns = df.columns.str.strip()
9 df = df.apply(lambda x: x.str.strip() if x.dtype == "object"
10               else x)
11
12 # Pretvaranje cijena i kilometraže u numericke tipove
13 df['price'] = pd.to_numeric(df['price'])
14 df['mileage'] = pd.to_numeric(df['mileage'])
15
16 # Standardizacija naziva proizvođača
17 df = df.rename(columns={'Manufacturer': 'manufacturer'})
18 df['manufacturer'] = df['manufacturer'].str.lower()
19 df['manufacturer'] = df['manufacturer'].replace({
20     'bmw': 'BMW',
21     'merc': 'Mercedes-Benz',
22     'volkswagen': 'Volkswagen',
23     'toyota': 'Toyota',
24     'hyundai': 'Hyundai',
25     'vauxhall': 'Vauxhall',
26     'audi': 'Audi',
27     'skoda': 'Skoda',
28     'ford': 'Ford'
29 })
```

```

29 # Uklanjanje redaka s nedostajucim vrijednostima
30 df = df.dropna()

```

3.3.2 Proširenje skupa podataka hijerarhijskim atributima

Jedan od ključnih koraka u pripremi podataka za skladište bilo je proširenje originalnog skupa s dodatnim atributima koji omogućuju stvaranje bogatijih hijerarhija i boljih analitičkih mogućnosti. Ovaj proces je implementiran kroz dodavanje sljedećih dimenzija:

Listing 3: Proširenje skupa podataka novim dimenzijama

```

1 # Dodavanje desetljeća na temelju godine proizvodnje
2 df['decade'] = (df['year'] // 10 * 10).astype(str) + 's'
3
4 # Mapiranje proizvođača na zemlje i regije
5 manufacturer_mapping = {
6     'Hyundai': {'country': 'South Korea', 'region': 'Asia'},
7     'Volkswagen': {'country': 'Germany', 'region': 'Europe'},
8     },
9     'BMW': {'country': 'Germany', 'region': 'Europe'},
10    'Skoda': {'country': 'Czech Republic', 'region': 'Europe'},
11    },
12    'Ford': {'country': 'United States', 'region': 'North America'},
13    },
14    'Toyota': {'country': 'Japan', 'region': 'Asia'},
15    'Mercedes-Benz': {'country': 'Germany', 'region': 'Europe'},
16    },
17    'Vauxhall': {'country': 'United Kingdom', 'region': 'Europe'},
18    },
19    'Audi': {'country': 'Germany', 'region': 'Europe'}
20 }
21
22 # Dodavanje geografskih dimenzija
23 df['country'] = df['manufacturer'].map(
24     lambda mfr: manufacturer_mapping.get(mfr, {}).get('country', 'Unknown'))
25 df['region'] = df['manufacturer'].map(
26     lambda mfr: manufacturer_mapping.get(mfr, {}).get('region', 'Unknown'))
27
28 # Kategorizacija kilometraže
29 mileage_ranges = [
30     (0, 5000, 'Very Low'),
31     (5000, 20000, 'Low'),
32     (20000, 50000, 'Medium'),
33     (50000, 100000, 'High'),
34     (100000, 150000, 'Very High'),
35     (150000, float('inf'), 'Extreme')

```

```

31 ]
32
33 df['mileageCategory'] = 'Unknown'
34 for low, high, category in mileage_ranges:
35     mask = (df['mileage'] >= low) & (df['mileage'] < high)
36     df.loc[mask, 'mileageCategory'] = category
37
38 # Klasifikacija velicine motora
39 engine_size_classes = [
40     (0.1, 1.5, 'Small'),
41     (1.5, 2.5, 'Medium'),
42     (2.5, float('inf'), 'Large')
43 ]
44
45 df['engineSizeClass'] = 'Unknown'
46 for low, high, category in engine_size_classes:
47     mask = (df['engineSize'] >= low) & (df['engineSize'] <
48         high)
49     df.loc[mask, 'engineSizeClass'] = category
50
51 # Dodavanje starosti vozila i kategorizacije
52 current_year = 2025
53 df['age'] = current_year - df['year']
54
55 age_categories = [
56     (0, 3, 'New'),
57     (3, 7, 'Recent'),
58     (7, 12, 'Mature'),
59     (12, 20, 'Old'),
60     (20, float('inf'), 'Vintage')
61 ]
62
63 df['ageCategory'] = 'Unknown'
64 for low, high, category in age_categories:
65     mask = (df['age'] >= low) & (df['age'] < high)
66     df.loc[mask, 'ageCategory'] = category

```

3.3.3 Podjela skupa podataka za simulaciju različitih izvora

Za potrebe demonstracije ETL procesa koji može rukovati podacima iz različitih izvora, prošireni skup podataka podijeljen je na dva dijela u omjeru 80:20. Ovaj pristup omogućuje simulaciju realnog scenarija gdje skladište podataka prima informacije iz više nezavisnih sustava.

Listing 4: Podjela skupa podataka na dva dijela

```

1 import pandas as pd
2
3 # Ucitavanje prosirenog skupa podataka

```

```

4 df = pd.read_csv("processed/cars_data_EXPANDED.csv",
5                 delimiter=',')
6
7 # Nasumična podjela u omjeru 80:20
8 df20 = df.sample(frac=0.2, random_state=1)
9 df80 = df.drop(df20.index)
10
11 print(Velicina 80% skupa:", df80.shape)
12 print("Velicina 20% skupa:", df20.shape)
13
14 # Spremanje u zasebne datoteke
15 df80.to_csv("processed/cars_data_80.csv", index=False)
16 df20.to_csv("processed/cars_data_20.csv", index=False)

```

3.4 Rezultati pripreme podataka

Na završetku procesa pripreme podataka, od originalnog skupa s 10 atributa stvaren je prošireni dataset s 16 atributa koji uključuje:

- **Originalne attribute** - svih 10 osnovnih karakteristika vozila
- **Temporalne dimenzije** - decade, age, ageCategory
- **Geografske dimenzije** - country, region
- **Kategorizirane attribute** - mileageCategory, engineSizeClass

Ovakav pristup pripreme podataka osigurava da konačni skup sadrži sve potrebne elemente za stvaranje bogatog dimenzijskog modela koji može podržati kompleksne OLAP analize. Dodatne hijerarhije omogućuje implementaciju naprednih analitičkih scenarija poput drill-down operacija od regije prema specifičnim modelima automobila, ili roll-up agregacija od individualnih vozila prema tržišnim segmentima.

Pripravljeni podaci predstavljaju čvrstu osnovu za sljedeću fazu projekta - dizajn i implementaciju relacijskog modela podataka koji će služiti kao izvor za ETL proces prema dimenzijskom skladištu podataka.

4 Relacijski model podataka

Nakon uspješno provedene analize podataka, sljedeći korak u razvoju skladišta podataka predstavlja kreiranje relacijskog modela koji će osigurati strukturirano i normalizirano čuvanje podataka. Relacijski model omogućuje organizaciju podataka u tablice povezane preko stranih ključeva, što omogućava efikasno dohvaćanje i manipulaciju podataka [9].

4.1 Analiza entiteta i atributa

Temeljito razumijevanje strukture podataka o automobilima omogućilo je identifikaciju ključnih entiteta koji će činiti okosnicu relacijskog modela. Kroz analizu originalnog skupa podataka identificirani su sljedeći glavni entiteti:

Osnovni entiteti:

- **Automobil** - središnji entitet koji sadrži osnovne karakteristike vozila
- **Proizvođač** - entitet koji predstavlja tvrtke koje proizvode automobile
- **Model** - specifični model automobila određenog proizvođača
- **Zemlja** - zemlja podrijetla proizvođača
- **Regija** - geografska regija kojoj pripada zemlja

Klasifikacijski entiteti:

- **Tip mjenjača** - klasifikacija prema vrsti transmisije
- **Tip goriva** - kategorije goriva koje automobil koristi
- **Desetljeće** - vremenski period proizvodnje
- **Kategorija starosti** - klasifikacija prema godinama starosti
- **Kategorija kilometraže** - klasifikacija prema prijednim kilometrima
- **Klasa veličine motora** - kategorije prema volumenu motora

Ova kategorizacija omogućuje stvaranje normaliziranog modela koji minimizira redundanciju podataka i omogućuje efikasne upite.


4.2 Konceptualni model podataka

Konceptualni model predstavlja visokorazinsku apstrakciju poslovnih zahtjeva bez ulaska u tehnička ograničenja. Za potrebe ovog projekta definiran je model koji odražava prirodne veze između entiteta u domeni trgovine automobilima.

Ključne veze u modelu uključuju:

- Svaki automobil pripada određenom modelu (1:N)
- Svaki model proizvodi točno jedan proizvođač (1:N)

- Svaki proizvođač dolazi iz jedne zemlje (1:N)
- Svaka zemlja pripada jednoj regiji (1:N)
- Automobil ima jednu kategoriju za svaki klasifikacijski atribut (1:N)




Slika 1: Konceptualni Entity-Relationship dijagram

ER dijagram prikazuje kompletan konceptualni model s entitetima, atributima i vezama između njih. Dijagram je kreiran koristeći standardnu notaciju koja jasno označava kardinalnosti i ograničenja. Na dijagramu je jasno vidljiva hijerarhijska struktura od regije do modela automobila, kao i klasifikacijski entiteti koji omogućuju analitičko izvještavanje. Svaki entitet sadrži primarni ključ i relevantne attribute koji podržavaju analitičke zahtjeve.

4.3 Implementacija relacijskog modela

Logički model podataka implementiran je koristeći MySQL bazu podataka, pri čemu je osobita pozornost posvećena normalnim formama i referencijalnim ograničenjima. Model slijedi treću normalnu formu (3NF) što osigurava minimizaciju redundancije podataka.



Slika 2: Implementirani relacijski model u MySQL bazi podataka

Implementacija uključuje:

- **Referencijalnu cjelovitost** - svi strani ključevi osiguravaju postojanje povezanih zapisa
- **Jedinstvene ograničenja** - sprječavanje dupliciranja entiteta
- **NOT NULL ograničenja** - osiguravanje kompletnosti kritičnih atributa
- **Auto-increment primarni ključevi** - efikasno upravljanje identifikatorima

4.4 Automatizacija kreiranja i popunjavanja baze

Za potrebe reproducibilnosti i održivosti projekta razvijene su Python skripte koje automatiziraju proces kreiranja i popunjavanja baze podataka. Glavna skripta koristi SQLAlchemy ORM za definiranje sheme baze.

Listing 5: Definiranje ORM modela za glavni entitet automobila

```
1 class Car(Base):
2     __tablename__ = 'car'
3     car_id = Column(Integer, primary_key=True, autoincrement
4                     =True)
5     year = Column(Integer, nullable=False)
6     price = Column(Integer, nullable=False)
7     mileage = Column(Integer, nullable=False)
8     tax = Column(Integer, nullable=False)
9     mpg = Column(Float, nullable=False)
10    engineSize = Column(Float, nullable=False)
11    age = Column(Integer, nullable=False)
12
13    # Strani kljucevi
14    model_id = Column(Integer, ForeignKey('model.model_id'))
15    transmission_id = Column(Integer, ForeignKey('
16        transmission_type.transmission_id'))
17    fuel_id = Column(Integer, ForeignKey('fuel_type.fuel_id'
18        ))
19    # ... ostali strani kljucevi
```

Proces popunjavanja baze provodi se u kontroliranim fazama:

1. **Kreiranje osnovnih entiteta** - regije, zemlje, proizvođači
2. **Kreiranje klasifikacijskih tabela** - tipovi goriva, mjenjača, kategorije
3. **Kreiranje modela** - povezivanje s proizvođačima
4. **Umetanje automobila** - povezivanje sa svim referentnim entitetima

4.5 Validacija podataka i testiranje

Za osiguravanje ispravnosti procesa migracije podataka u zasebnoj skripti implementiran je sveobuhvatan sustav testiranja koji uspoređuje originalne CSV podatke s podacima u bazi.

Listing 6: SQL upit za rekonstrukciju originalnih podataka

```
1 query = """
2 SELECT mfg.name as 'manufacturer', mdl.name as 'model'
3 , c.year, c.price, c.mileage, c.tax, c.mpg, c.engineSize
4 , t.type as 'transmission', f.type as 'fuelType'
5 , d.decade, cnt.name as 'country', r.name as 'region'
6 , mc.category as 'mileageCategory'
7 , esc.size_class as 'engineSizeClass'
8 , c.age, ac.category as 'ageCategory'
9 FROM car c
10 JOIN model mdl ON c.model_id = mdl.model_id
11 JOIN manufacturer mfg ON mdl.manufacturer_id = mfg.
    manufacturer_id
```

```
12 -- ... ostali JOIN-ovi
13 ORDER BY c.car_id ASC
14 """
```

Test provjerava:

- **Integritet strukture** - postojanje svih stupaca u bazi
- **Kompletnost podataka** - broj zapisa u bazi odgovara CSV datoteci
- **Ispravnost sadržaja** - vrijednosti u bazi identične su originalnim podacima
- **Referencijalnu konzistentnost** - svi strani ključevi ispravno povezani

5 Dimenzijski model podataka

Nakon implementacije normaliziranog relacijskog modela, sljedeći korak u razvoju skladišta podataka predstavlja kreiranje dimenzijskog modela optimiziranog za analitičke upite i izvještavanje. Dimenzijski model, poznat i kao "star schema", omogućuje brže izvršavanje složenih analitičkih upita kroz denormalizirane strukture podataka [10].

5.1 Konceptualni pristup dimenzijskom modeliranju

Dimenzijski model predstavlja fundamentalno drugačiji pristup od tradicionalnog relacijskog modela. Umjesto fokusa na normalnu formu i eliminaciju redundancije, dimenzijski model optimizira strukturu za analitičke performance i razumljivost krajnjih korisnika [?].

Ključne karakteristike dimenzijskog pristupa uključuju:

Denormalizacija za performanse:

- Spojene tablice u široke dimenzije za smanjenje JOIN operacija
- Redundantni podaci prihvaćeni radi brzine upita
- Optimizacija za čitanje, a ne za pisanje podataka

Intuitivnost za analitičare:


- Jasno razlikovanje između činjenica (mjera) i dimenzija (kontekst)
- Prirodno mapiranje na poslovne procese i izvještaje
- Jednostavnost za ad-hoc analize i OLAP operacije

Upravljanje promjenama kroz vrijeme:

- Implementacija Slowly Changing Dimensions (SCD) strategija
- Održavanje povijesnih podataka za trendove analize
- Fleksibilnost u dodavanju novih dimenzija i mjera

5.2 Arhitektura zvjezdastog modela

Za potrebe analize automobilskeg tržišta dizajnirana je star schema koja omogućuje dubinsku analizu prodajnih trendova, cijena i karakteristika vozila kroz različite dimenzije.



Slika 3: Star schema dimenzijskog modela za analizu automobilske tržišta

Model se sastoji od:

- **1 tablica činjenica** (Fact_Car_Sales) - centralna tablica s mjerama
- **9 dimenzijskih tablica** - kontekstualne informacije za analizu
- **Surrogate ključevi** - tehničke veze između tablica
- **SCD implementacija** - upravljanje promjenama kroz vrijeme

5.3 Tablica činjenica - Fact_Car_Sales

Središnja tablica činjenica predstavlja glavni repozitorij svih prodajnih činjenica vezanih uz automobile na tržištu. Tablica je optimizirana za agregacijske operacije i analitičke upite.

Listing 7: Definiranje tablice činjenica u SQLAlchemy ORM-u

```
1 class FactCarSales(Base):
2     __tablename__ = 'fact_car_sales'
3
4     car_sales_tk = Column(BigInteger, primary_key=True,
5                             autoincrement=True)
6
7     # Strani ključevi prema dimenzijama
8     date_tk = Column(Integer, ForeignKey('dim_date.date_tk'))
9     manufacturer_tk = Column(BigInteger, ForeignKey('dim_manufacturer.manufacturer_tk'))
10    vehicle_tk = Column(BigInteger, ForeignKey('dim_vehicle.vehicle_tk'))
11    transmission_tk = Column(BigInteger, ForeignKey('dim_transmission.transmission_tk'))
12    fuel_tk = Column(BigInteger, ForeignKey('dim_fuel.fuel_tk'))
13
14    # Mjere za analizu
15    price = Column(DECIMAL(10, 2), nullable=False) # Glavna mjera
16    mileage = Column(Integer, nullable=False)
17    tax = Column(Integer, nullable=False)
18    mpg = Column(DECIMAL(5, 2), nullable=False)
19    engine_size = Column(DECIMAL(3, 1), nullable=False)
20    age = Column(Integer, nullable=False)
```

Tablica sadrži sljedeće tipove atributa:

- **Surrogate ključ** - tehnički identifikator zapisa (car_sales_tk)
- **Strani ključevi** - veze s dimenzijskim tablicama
- **Mjere** - kvantitativni podaci za agregaciju i analizu
- **Audit polja** - praćenje kreiranja i ažuriranja podataka

5.4 Dimenzijske tablice i SCD strategije

Dimenzijske tablice pružaju kontekstualne informacije potrebne za interpretaciju činjenica. Ovisno o prirodi podataka, implementirane su različite SCD (Slowly Changing Dimensions) strategije.

SCD Type 0 - Statični podaci (Dim_Date):

- Podaci se nikad ne mijenjaju
- Jednostavna struktura bez povijesnih zapisa
- Koristi se za vremensku dimenziju

SCD Type 1 - Prepisivanje (Dim_Transmission, Dim_Location):

- Nova vrijednost zamjenjuje staru
- Nema čuvanja povijesti promjena
- Koristi se za podatke gdje povijest nije kritična

Listing 8: SCD Type 1 implementacija za tip mjenjača

```

1 class DimTransmission(Base):
2     __tablename__ = 'dim_transmission'
3
4     transmission_tk = Column(BigInteger, primary_key=True,
5                               autoincrement=True)
6     transmission_id = Column(Integer, nullable=False, index=
7                           True) # Business key
8     type = Column(String(20), nullable=False)
9     last_updated = Column(DateTime, default=datetime.now,
10                           onupdate=datetime.now)
11     created_date = Column(DateTime, default=datetime.now)

```

SCD Type 2 - Dodavanje novih zapisa (Dim_Manufacturer, Dim_Vehicle, ostali):

- Čuva se potpuna povijest promjena
- Svaka promjena kreira novi zapis
- Omogućuje analizu trendova kroz vrijeme

Listing 9: SCD Type 2 implementacija za proizvođače

```

1 class DimManufacturer(Base):
2     __tablename__ = 'dim_manufacturer'
3
4     manufacturer_tk = Column(BigInteger, primary_key=True,
5                               autoincrement=True)
6     version = Column(Integer, nullable=False, default=1)
7     date_from = Column(DateTime, nullable=False, default=
8                     datetime.now)
9     date_to = Column(DateTime, nullable=True)
10    manufacturer_id = Column(Integer, nullable=False, index=
11                          True) # Business key
12    name = Column(String(100), nullable=False)
13    country = Column(String(50), nullable=False)

```



```

11     region = Column(String(50), nullable=False)
12     is_current = Column(Boolean, nullable=False, default=
        True)

```

5.5 Prednosti zvjezdastog modela

Implementacija star schema modela donosi značajne prednosti za analitičke procese:

Performanse upita:

- Smanjenje složenosti JOIN operacija
- Optimizacija za agregacijske funkcije
- Predictable execution planovi za OLAP upite

Skalabilnost:

- Linearan rast s volumenom podataka
- Mogućnost horizontalnog particioniranja
- Kompatibilnost s distribuiranim analitičkim sustavima

Jednostavnost korištenja:

- Intuitivna struktura za poslovne analitičare
- Izravno mapiranje na OLAP kočke
- Kompatibilnost s BI alatima (Tableau, Power BI, itd.)

5.6 Implementacijski detalji

Kreiranje dimenzijskog modela automatizirano je kroz Python skriptu koja osigurava konzistentnost strukture i referencijalnih veza.

Listing 10: Kreiranje star schema strukture

```

1  # Kreiranje baze podataka za data warehouse
2  temp_engine = create_engine('mysql+pymysql://root:
    root@localhost', echo=False)
3  with temp_engine.connect() as conn:
4      conn.execute(text("CREATE DATABASE IF NOT EXISTS cars_dw
        CHARACTER SET utf8mb4"))
5      conn.commit()
6
7  # Kreiranje svih tablica u dimenzijskom modelu
8  Base.metadata.drop_all(engine)  # Uklanjanje postojećih
    tablica
9  Base.metadata.create_all(engine)  # Kreiranje novih tablica
10
11 print("Star Schema tables created successfully!")

```

Model je spreman za ETL proces koji će popuniti dimenzije i tablicu činjenica podacima iz relacijske baze, pri čemu će se implementirati potrebne SCD strategije za upravljanje promjenama kroz vrijeme.

6 ETL proces

ETL (Extract, Transform, Load) proces predstavlja srce svakog skladišta podataka, omogućujući transformaciju heterogenih izvornih podataka u konzistentan, analitički optimiziran format. Za potrebe ovog projekta implementiran je sveobuhvatan ETL pipeline koji kombinira podatke iz relacijske baze i CSV datoteka, transformira ih u dimenzijski model i učitava u skladište podataka.

6.1 Arhitektura ETL pipelinea

ETL proces projektiran je prema modernim načelima scalable data processing korištenjem Apache Spark okruženja koje omogućuje distribuirano procesiranje velikih količina podataka [11].

Ključne komponente arhitekture uključuju:

Tehnološki stack:

- **Apache Spark** - distribuirano procesiranje podataka
- **PySpark** - Python API za Spark s DataFrame optimizacijama
- **JDBC konektor** - povezivanje s MySQL bazama podataka
- **SQLAlchemy ORM** - objektno-relacionalno mapiranje za schema management

Modularni dizajn:

- Razdvojene Extract, Transform i Load faze
- Nezavisan kod za svaku dimenziju i tablicu činjenica
- Mogućnost pokretanja pojedinačnih komponenti za testiranje
- Centralizirano upravljanje Spark sesijama

Listing 11: Inicijalizacija Spark okruženja za ETL pipeline

```
1 def get_spark_session(app_name="ETL_App"):  
2     project_root = os.path.dirname(os.path.dirname(os.path.  
3         abspath(__file__)))  
4     mysql_jar_path = os.path.join(project_root, "Connectors"  
5         , "mysql-connector-j-9.2.0.jar")  
6  
7     return SparkSession.builder \  
8         .appName(app_name) \  
9         .config("spark.jars", mysql_jar_path) \  
10        .config("spark.driver.host", "127.0.0.1") \  
11        .config("spark.sql.adaptive.enabled", "false") \  
12        .config("spark.serializer", "org.apache.spark.  
13            serializer.KryoSerializer") \  
14        .getOrCreate()
```

6.2 Extract faza - izvlačenje podataka

Extract faza odgovorna je za dohvaćanje podataka iz heterogenih izvora i njihovo ujedinjavanje u Spark DataFrame strukture pogodne za daljnju obradu.

Izvlačenje iz MySQL baze podataka:

Implementiran je generički sustav za dohvaćanje svih tablica iz relacijske baze koristeći JDBC konektor koji omogućuje optimiziranu komunikaciju između Spark-a i MySQL-a.

Listing 12: Izvlačenje podataka iz MySQL relacijske baze

```
1 def extract_table(table_name, database="cars"):
2     spark = get_spark_session("ETL_Extract_MySQL")
3
4     jdbc_url = f"jdbc:mysql://127.0.0.1:3306/{database}?
5         useSSL=false&allowPublicKeyRetrieval=true"
6     connection_properties = {
7         "user": "root",
8         "password": "root",
9         "driver": "com.mysql.cj.jdbc.Driver"
10    }
11
12    try:
13        df = spark.read.jdbc(url=jdbc_url, table=table_name,
14            properties=connection_properties)
15        return df
16    except Exception as e:
17        print(f"Error extracting table {table_name}: {e}")
18        return spark.createDataFrame([], "struct<id:int>")
```

Izvlačenje iz CSV datoteka:

Za fleksibilnost i potporu dodatnim izvorima podataka, implementirana je mogućnost učitavanja podataka iz CSV datoteka koje mogu sadržavati nove zapise ili dopunske informacije.

Listing 13: Izvlačenje podataka iz CSV datoteka

```
1 def extract_from_csv(file_path):
2     spark = get_spark_session("ETL_Extract - CSV")
3     df = spark.read.option("header", True).option("
4         inferSchema", True).csv(file_path)
5     return df
```

6.3 Transform faza - transformacija podataka

Transform faza predstavlja najkompleksniji dio ETL procesa gdje se izvlačeni podaci transformiraju u dimenzijski model optimiziran za analitičke operacije.

6.3.1 Transformacija dimenzijskih tablica

Svaka dimenzijska tablica implementira odgovarajuću SCD strategiju prema prirodi podataka i poslovnim zahtjevima:

SCD Type 0 - Statična vremenska dimenzija:

Listing 14: Transformacija vremenske dimenzije

```
1 def transform_date_dim(car_df, csv_cars_df=None):
2     # Izvlacenje jedinstvenih godina iz baze
3     mysql_df = (
4         car_df
5         .select(col("year"))
6         .dropDuplicates()
7         .withColumn("decade", concat(((col("year").cast("int")
8             ) / 10).cast("int") * 10).cast("string"), lit("s
9             ")))
10        .select("year", "decade")
11    )
12
13    # Dodavanje surrogate ključa
14    final_df = mysql_df.withColumn("date_tk", col("year"))
15    return final_df
```

SCD Type 1 - Prepisivanje za jednostavne entitete:

Koristi se za podatke poput tipova mjenjača gdje povijest promjena nije kritična.

Listing 15: SCD Type 1 implementacija za tip mjenjača

```
1 def transform_transmission_dim(transmission_type_df,
2     csv_cars_df=None):
3     merged_df = (
4         transmission_type_df
5         .select(
6             col("transmission_id"),
7             trim(col("type")).alias("type")
8         )
9         .withColumn("type", initcap(trim(col("type"))))
10        .dropDuplicates()
11    )
12
13    # Dodavanje audit polja
14    merged_df = merged_df.withColumn("last_updated",
15        current_timestamp())
16
17    # Surrogate key
18    window = Window.orderBy("type")
19    merged_df = merged_df.withColumn("transmission_tk",
20        row_number().over(window))
21
22    return merged_df
```

SCD Type 2 - Praćenje povijesti za ključne entitete:

Implementiran je za proizvođače, vozila i tipove goriva gdje je održavanje povijesti promjena kritično za analize trendova.

Listing 16: SCD Type 2 implementacija za proizvođače

```
1 def transform_manufacturer_dim(manufacturer_df, country_df,
2   region_df, csv_cars_df=None):
3     # Spajanje s geografskim informacijama
4     merged_df = (
5         manufacturer_df.alias("m")
6         .join(country_df.alias("c"), col("m.country_id") ==
7             col("c.country_id"), "left")
8         .join(region_df.alias("r"), col("c.region_id") ==
9             col("r.region_id"), "left")
10        .select(
11            col("m.manufacturer_id").alias("manufacturer_id"),
12            trim(col("m.name")).alias("name"),
13            trim(col("c.name")).alias("country"),
14            trim(col("r.name")).alias("region")
15        )
16    )
17
18    # SCD Type 2 polja
19    merged_df = merged_df.withColumn("version", lit(1)) \
20        .withColumn("date_from",
21            current_timestamp()) \
22        .withColumn("date_to", lit(None).
23            cast("timestamp")) \
24        .withColumn("is_current", lit(True))
25
26    return merged_df
```

6.3.2 Transformacija tablice činjenica

Tablica činjenica predstavlja najveći izazov zbog potrebe za spajanjem podataka iz svih dimenzija i osiguravanjem referencijalnih veza.

Listing 17: Kreiranje tablice činjenica

```
1 def transform_car_sales_fact(raw_data, manufacturer_dim,
2   vehicle_dim, transmission_dim,
3   fuel_dim, location_dim, date_dim,
4   mileage_category_dim,
5   engine_size_class_dim,
6   age_category_dim):
7
8     # Priprema činjenica iz baze podataka
```

```

6     fact_df = prepare_fact_from_database(raw_data["car"],
7                                         raw_data)
8
9     # Dodavanje podataka iz CSV-a ako postoje
10    if "csv_cars" in raw_data and raw_data["csv_cars"] is
11        not None:
12        csv_fact_df = prepare_fact_from_csv(raw_data["
13            csv_cars"])
14        fact_df = fact_df.unionByName(csv_fact_df)
15
16    # Dimension lookups za Foreign Key-eve
17    fact_with_dims = perform_dimension_lookups(
18        fact_df, manufacturer_dim, vehicle_dim,
19        transmission_dim,
20        fuel_dim, location_dim, date_dim,
21        mileage_category_dim,
22        engine_size_class_dim, age_category_dim
23    )
24
25    return fact_with_dims

```

Ključni aspekti transformacije:

- **Data cleansing** - uklanjanje neispravnih i nedosljednih podataka
- **Standardizacija** - ujedinjavanje formata i kodiranja
- **Surrogate key generiranje** - kreiranje tehničkih identifikatora
- **Dimension lookup** - mapiranje business ključeva na surrogate ključeve
- **Data enrichment** - dodavanje kategorijskih klasifikacija

6.4 Load faza - učitavanje u skladište podataka

Load faza odgovorna je za efikasno i sigurno učitavanje transformiranih podataka u ciljno skladište podataka, pri čemu se poštuju referencijalna ograničenja i optimiziraju performanse.

Strategija učitavanja:

Implementiran je pristup koji poštuje hijerarhiju foreign key veza između tablica, učitavajući najprije dimenzije, a zatim tablice činjenica.

Listing 18: Kontrolirano učitavanje s poštovanjem foreign key veza

```

1 def write_all_tables_to_mysql(load_ready_dict):
2     # Prvo uklanjanje tablica činjenica za izbjegavanje FK
3     konflikata
4     drop_fact_tables_first()
5
6     # Redoslijed učitavanja: dimenzije prvo

```

```

6     dimension_tables = ['dim_manufacturer', 'dim_vehicle', '
7         dim_transmission',
8         'dim_fuel', 'dim_location', 'dim_date',
9         'dim_mileage_category', '
10         dim_engine_size_class', '
11         dim_age_category']
12     fact_tables = ['fact_car_sales']
13
14     # Učitavanje dimenzija
15     for table_name in dimension_tables:
16         if table_name in load_ready_dict:
17             write_spark_df_to_mysql(load_ready_dict[
18                 table_name], table_name)
19
20     # Zatim učitavanje činjenica
21     for table_name in fact_tables:
22         if table_name in load_ready_dict:
23             write_spark_df_to_mysql(load_ready_dict[
24                 table_name], table_name)

```

JDBC optimizacije:

Učitavanje koristi JDBC batch operacije za optimalne performanse, s mogućnosti fallback-a na CSV export u slučaju tehničkih problema.

Listing 19: Optimizirano JDBC učitavanje s fallback strategijom

```

1 def write_spark_df_to_mysql(spark_df: DataFrame, table_name:
2     str, mode: str = "overwrite"):
3     jdbc_url = "jdbc:mysql://127.0.0.1:3306/cars_dw?useSSL=
4         false&allowPublicKeyRetrieval=true"
5     connection_properties = {
6         "user": "root",
7         "password": "root",
8         "driver": "com.mysql.cj.jdbc.Driver"
9     }
10
11     try:
12         spark_df.write.jdbc(
13             url=jdbc_url,
14             table=table_name,
15             mode=mode,
16             properties=connection_properties
17         )
18         print(f"Uspjesno ucitano {spark_df.count()} zapisa u
19             tablicu {table_name}")
20
21     except Exception as e:
22         print(f"Greska pri ucitavanju: {e}")
23         # Fallback na CSV export

```



```

21     output_path = f"4_etl/output/{table_name}.csv"
22     spark_df.coalesce(1).write.mode(mode).option("header", "true").csv(output_path)

```

6.5 Orkestracija i monitoring

Kompletan ETL pipeline orchestriran je kroz glavnu skriptu koja koordinira sve faze i omogućuje praćenje napretka.

Listing 20: Glavna ETL orkestracija

```

1  def main():
2      spark = get_spark_session()
3      spark.sparkContext.setLogLevel("ERROR")
4
5      # Extract faza
6      print("Pocinje izvlacenje podataka...")
7      mysql_df = extract_all_tables()
8      csv_df = {"csv_cars": extract_from_csv("2
          _relational_model/processed/cars_data_20.csv")}
9      merged_df = {**mysql_df, **csv_df}
10     print("Izvlacenje podataka zavrшено")
11
12     # Transform faza
13     print("Pocinje transformacija podataka...")
14     load_ready_dict = run_transformations(merged_df)
15     print("Transformacija podataka završena")
16
17     # Load faza
18     print("Pocinje učitavanje podataka...")
19     write_all_tables_to_mysql(load_ready_dict)
20     print("ETL proces uspješno završen")

```

6.6 Prednosti implementiranog ETL rješenja

Razvijeni ETL proces donosi značajne prednosti za upravljanje skladištem podataka:

Skalabilnost i performanse:

- Apache Spark omogućuje distribuirano procesiranje velikih volumena
- Lazy evaluation optimizira izvršavanje kompleksnih transformacija
- In-memory computing ubrzava iterativne operacije

Fleksibilnost i proširivost:

- Modularni dizajn omogućuje lako dodavanje novih izvora podataka
- Podrška za različite SCD strategije prema poslovnim zahtjevima

- Mogućnost pokretanja pojedinačnih komponenti za testiranje i debugging

Pouzdanost i održivost:

- Fallback strategije za slučajeve tehničkih problema
- Detaljno logiranje za praćenje i dijagnostiku
- Transakcijska sigurnost kroz kontrolirano učitavanje

Ovakav pristup osigurava da skladište podataka bude ažurno, konzistentno i spremno za složene analitičke operacije potrebne za poslovne analize i izvještavanje [12].

7 OLAP analiza

Nakon uspješne implementacije ETL procesa i popunjavanja skladišta podataka, konačni korak predstavlja izvršavanje OLAP (Online Analytical Processing) analiza koje omogućuju dubinsko razumijevanje poslovnih trendova i donošenje informiranih odluka. OLAP sustavi omogućuju brze, interaktivne analize velikih količina podataka kroz višedimenzijski pristup [13].

7.1 Osnove OLAP tehnologija

OLAP predstavlja kategoriju softverskih alata optimiziranih za analizu i izvještavanje nad skladištima podataka. Za razliku od OLTP (Online Transaction Processing) sustava koji su optimizirani za transakcijske operacije, OLAP sustavi su dizajnirani za analitičke upite koji često zahtijevaju agregirane podatke kroz više dimenzija [14].

Ključne karakteristike OLAP sustava uključuju:

Višedimenzijski pristup:

- Podatci se organiziraju u kocke (cubes) s više dimenzija
- Omogućuju slice, dice, drill-down i roll-up operacije
- Intuitivna navigacija kroz hijerarhije podataka

Interaktivnost i brzina:

- Sub-sekundni odgovor na kompleksne upite
- Mogućnost dinamičkog mijenjanja perspektive analize
- Real-time istraživanje podataka

Složene kalkulacije:

- Podrška za složene poslovne upite i kalkulacije
- Vremensko modeliranje i trend analiza
- What-if scenariji i prediktivne analize

7.2 Tableau kao OLAP alat

Za potrebe ovog projekta odabran je Tableau kao vodeći alat za poslovnu inteligenciju koji omogućuje korištenje OLAP funkcionalnosti kroz intuitivno sučelje za vizualizaciju podataka [15]. Tableau se izravno povezuje na naše MySQL skladište podataka i omogućuje explorativnu analizu po jednostavnom drag-and-drop principu.

Prednosti Tableau-a za OLAP analize:

- **Izravna povezanost** s MySQL skladištem podataka


- **Automatsko prepoznavanje** hierarchija i veza
- **Interaktivne vizualizacije** s drill-down mogućnostima
- **Real-time analiza** bez potrebe za predkompajliranim kockama

7.3 Analiza cijena kroz dimenzije

Prva skupina analiza fokusira se na ponašanje cijena automobila kroz različite dimenzije, omogućujući identifikaciju ključnih čimbenika koji utječu na vrednovanje vozila.

7.3.1 Regionalna analiza cijena

Analiza prosječnih cijena po regijama i desetljećima otkriva značajne geografske i vremenske trendove na automobilskom tržištu.




Slika 4: Prosječna cijena automobila po desetljeću i regiji

Vizualizacija otkriva jasne regionalne i vremenske trendove na automobilskom tržištu. Europski proizvođači konzistentno postižu najviše prosječne cijene kroz sva desetljeća (od 17.747€ u 1970-ima do 30.349€ u 2020-ima), što potvrđuje njihovo pozicioniranje u premium segmentu. Azijski proizvođači zauzimaju srednji cjenovni segment s rastućim trendom od 1990-ih (10.993€) do 2020-ih (21.209€), dok sjevernoamerički proizvođači pokazuju najniže prosječne cijene kroz većinu razdoblja, s izuzetkom značajnog rasta u 2020-ima (20.767€). Ova analiza predstavlja klasičnu OLAP operaciju roll-up po vremenskoj i geografskoj hijerarhiji.

7.3.2 Analiza po zemljama proizvođača

Dublja analiza po zemljama proizvođača omogućuje preciznije razumijevanje konkurentnosti na globalnom tržištu.




Slika 5: Prosječna cijena automobila po zemlji proizvođača

Rezultati pokazuju da njemački proizvođači održavaju najviše prosječne cijene, što odražava pozicioniranje na premium tržištu, dok korejski, japanski i američki proizvođači nude kompetitivne cijene u masovnom tržišnom segmentu. Automobili britanskih proizvođača generalno su pristupačniji i povoljniji široj publici.

7.3.3 Vremenska analiza cijena

Longitudinalna analiza kretanja cijena kroz vremenski period omogućuje dublje razumijevanje tržišne dinamike i procesa gubitka vrijednosti vozila.

Prosječna cijena automobila po godini i desetljeću



Slika 6: Prosječna cijena automobila po godini i desetljeću

Vizualizacija prikazuje značajne fluktuacije tržišnih cijena kroz različita desetljeća. Najviše prosječne cijene zabilježene su u 1970-ima (oldtimeri) (17.747€) i 2020-ima (29.108€ u 2020.), dok su najniže cijene karakteristične za 2000-e godine (3.017-4.524€). Posebno je uočljiv eksponencijalni rast cijena kroz 2010-e godine, od 5.286€ u 2010. do 23.570€ u 2019., što odražava tehnološki napredak, premiumizaciju tržišta i inflacijske pritiske na automobilsku industriju.

7.4 Analiza proizvođača i modela

Druga skupina analiza istražuje performanse proizvođača i specifičnih modela, omogućujući rangiranje prema različitim kriterijima.

7.4.1 Top modeli po cijeni

Identifikacija najskupljih modela pruža uvid u luksuzni segment tržišta.

Top Models by price


Max. Pri..	Manufacturer Na..	Model Name	
159,999	Mercedes-benz	G Class	●
149,948	Mercedes-benz	SL Class	●
145,000	Audi	R8	●
140,319	Mercedes-benz	A Class	●
124,999	Mercedes-benz	S Class	●
123,456	Bmw	2 Series	●
109,495	Audi	Rs6	●
99,950	Bmw	M4	●
92,000	Hyundai	I10	●
91,874	Skoda	Karoq	●

Slika 7: Top modeli automobila prema cijeni

Analiza otkriva dominaciju njemačkih premium proizvođača u vrhu cjenovne hijerarhije, s Mercedes-Benzom koji drži četiri od deset najskupljih pozicija (G Class 159.999€, SL Class 149.948€, A Class 140.319€, S Class 124.999€). BMW i Audi također snažno su zastupljeni s modelima poput BMW 2 Series (123.456€), BMW M4 (99.950€) i Audi R8 (145.000€), Audi RS6 (109.495€). Zanimljivo je prisustvo Hyundai I10 (92.000€) i Škoda Karoq (91.874€) među top modelima, što ukazuje na probijanje tradicionalno mass-market brandova u luksuzni segment.

7.4.2 Odnos cijene i veličine motora

Scatter plot analiza otkriva korelaciju između tehničkih specifikacija i cijene.




Slika 8: Odnos cijene i veličine motora po proizvođaču

Scatter plot analiza jasno potvrđuje snažnu pozitivnu korelaciju između veličine motora i cijene vozila, pri čemu svaki proizvođač demonstrira distinktivnu strategiju pozicioniranja. Audi (plava linija) pokazuje najstrmiji gradijent rasta cijene s veličinom motora, što odražava agresivno premium pozicioniranje s izrazitim fokusom na performanse većih motora. Mercedes-Benz (zeleni) također pokazuje snažan trend rasta, ali s nešto umjerenijim nagibom, dok BMW (narančasti) i Volkswagen (ljubičasti) pokazuju umjerene ali konzistentne trendove. Azijski proizvođači Toyota (ružičasti) i Hyundai (tirkizni) uglavnom se pozicioniraju u nižim cjenovnim segmentima neovisno o veličini motora, što ukazuje na strategiju value-for-money. Škoda (žuti) i Ford (crveni) zauzimaju srednji segment s predvidljivim linearnim trendovima, što potvrđuje različite poslovne strategije od mass-market pristupa do premium pozicioniranja.

7.4.3 Analiza po tipu motora

Heat mapa pokazuje prosječne cijene prema proizvođačima i tipovima motora.

Prosječna cijena automobila po proizvođaču u odnosu na tip motora




Slika 9: Prosječna cijena automobila po proizvođaču u odnosu na tip motora

Heat mapa analiza otkriva jasne cjenovne razlike između tipova motora kroz sve proizvođače. Hibridni motori dominiraju u cijeni s prosječnim cijenama od 10.948€ (Vauxhall) do 31.225€ (Škoda), pri čemu premium brandovi BMW (27.154€) i Audi (30.191€) pozicioniraju hibride u luksuzni segment. Električni motori, iako ograničeno zastupljeni, pokazuju umjerene cijene (BMW 18.466€, Ford 15.737€, Vauxhall 12.999€). Dizelski motori zauzimaju srednji cjenovni segment s rasponom od 11.071€ (Vauxhall) do 23.216€ (Mercedes-Benz), dok benzinski motori pokazuju najširi spektar cijena od 9.754€ (Toyota) do 28.240€ (Mercedes-Benz), potvrđujući njihovu dominaciju kroz sve tržišne segmente. Kategorija "Other" (uključujući LPG i CNG) generalno se pozicionira između benzinskih i dizelskih motora po cijeni.

7.4.4 Detaljna analiza po modelu

Stupčasti dijagram pruža pregled prosječnih cijena po proizvođačima i modelima, rangirajući ih po vrijednosti.



Slika 10: Prosječna cijena vozila po proizvođaču i modelu

Stupčasti dijagram jasno demonstrira hijerarhiju vrijednosti kroz portfolije različitih proizvođača. Mercedes-Benz dominira premium segmentom s G Class modelom koji dostiže vrhunac od približno 100.000€, praćen S Class (45.000€) i A Class (40.000€) modelima, što potvrđuje strategiju vertikalnog pokrivanja luksuznog tržišta. Audi pokazuje najširi spektar cijena s flagship modelima (RS serija) koji dostižu 100.000€, demonstrirajući uspješnu premiumizaciju portfelja. BMW održava konzistentno visoke cijene kroz različite modele, potvrđujući pozicioniranje u upper-premium segmentu.

Volkswagen pokriva srednji do viši segment s modelima u rasponu 10.000-60.000€, što odražava strategiju "brand stretching" od mass-market prema premium pozicioniranju. Škoda iznenađuje s nekoliko modela u višem cjenovnom segmentu (25.000€), što ukazuje na uspješnu evoluciju od budget prema value-premium brandiranju. Azijski proizvođači Toyota i Hyundai uglavnom se pozicioniraju u nižem do srednjem segmentu (5.000-25.000€), s Hyundai koji pokazuje jedan premium model, što signalizira pokušaje probijanja u više segmente. Ford


i Vauxhall konzistentno zauzimaju najniži cjenovni segment (5.000-15.000€), potvrđujući focus na mass-market tržišnom segmentu.

7.5 Analiza eksploatacijskih karakteristika

Treća skupina analiza istražuje praktične aspekte korištenja vozila kroz kilometre, starost i potrošnju.

7.5.1 Odnos starosti i kilometraže

Scatter plot analiza otkriva obrazac korištenja vozila kroz vrijeme.



Slika 11: Odnos starosti i kilometraže automobila


Scatter plot vizualizacija s kategorizacijom vozila po starosti otkriva kompleksne obrasce korištenja kroz životni ciklus automobila. Vintage vozila (zelena, 20-55 godina starosti) pokazuju izuzetno varijabilnu kilometražu od minimalnih vrijednosti do preko 180.000 km, što odražava različite pristupe čuvanju - od garažnih koleksijskih primjeraka do svakodnevno korištenih klasika.

Old vozila (crvena, 10-20 godina) demonstriraju najširu distribuciju kilometraže s jasnim trendom rasta, gdje većina vozila akumulira 50.000-140.000 km, što predstavlja tipičan obrazac deprecijacije kroz intenzivnu upotrebu. Mature vozila (plava, 5-15 godina) pokazuju umjerenu pozitivnu korelaciju s koncentracijom u rasponu 5.000-140.000 km, što ukazuje na stabilnu fazu korištenja.

Recent vozila (tirkizna, 2-8 godina) uglavnom se nalaze u rasponu do 80.000 km s linearnim trendom rasta, dok New vozila (narančasta, 0-5 godina) pokazuju najnižu kilometražu od oko 55.000 km (samo jedan primjerak). Trend linije po kategorijama otkrivaju da vintage vozila imaju najpoloženiji nagib (minimalno godišnje povećanje kilometraže), dok old i mature kategorije pokazuju najstrmiji rast, što potvrđuje intenzivnu upotrebu u srednjim i kasnim godinama životnog ciklusa vozila.

7.5.2 Kilometraža po tipu motora

Box plot analiza prikazuje distribuciju kilometraže prema tipovima motora.



Slika 12: Prijeđeni kilometri po tipu motora

Stupčasti dijagram jasno demonstrira značajne razlike u obrascima korištenja vozila prema tipovima motora. Dizelski motori dominiraju s prosječno 330.000 km, što potvrđuje njihovu primarnu ulogu u long-haul aplikacijama, komercijalnim vozilima i dugotrajnim putovanjima gdje ekonomičnost goriva postaje kritična. Benzinski motori zauzimaju drugo mjesto s 185.000 km, što odražava njihovu široku primjenu u svakodnevnoj urbano-suburbanoj mobilnosti.

Hibridni motori s prosječno 180.000 km pokazuju slične obrasce korištenja kao benzinski, što ukazuje na njihovu uspješnu integraciju u mainstream tržišni segment. Kategorija "Other" (uključujući LPG, CNG i alternativna goriva) s 115.000 km pozicionira se kao srednje-kilometražni segment, vjerojatno zbog specifičnih infrastrukturnih ograničenja i ciljanih aplikacija.

Električni motori pokazuju najnižu prosječnu kilometražu od samo 35.000 km, što odražava kombinaciju faktora: relativno recentnu adaptaciju tehnologije, ograničenja doseg, koncentraciju na urbano korištenje, te činjenicu da mnogi električni automobili još uvijek nisu prošli potpuni životni ciklus na tržištu rabljenih vozila.


7.6 Tržišna analiza i trendovi

Četvrta skupina analiza fokusira se na makroekonomske trendove i tržišne udjele.

7.6.1 Udio proizvođača na tržištu

Treemap vizualizacija kombinira tržišni udio s prosječnim cijenama proizvođača kroz veličinu i boju pravokutnika.

Udio proizvođača na tržištu i prosječna cijena automobila



Slika 13: Udio proizvođača na tržištu i prosječna cijena automobila

Treemap vizualizacija s preciznim podacima otkriva jasne obrasce između tržišnog volumena i cjenovnog pozicioniranja proizvođača automobila. Ford dominira apsolutnim tržišnim udjelom s 17.811 prodanih vozila pri prosječnoj cijeni od 12.270€, što naglašava klasičnu mass-market strategiju kroz visoki volumen i pristupačne cijene. Volkswagen zauzima drugo mjesto s 14.893 vozila i prosječnom cijenom od 16.808€, demonstrirajući uspješno balansiranje između volumena i umjereno višeg pozicioniranja.


Vauxhall s 13.258 vozila i najnižom prosječnom cijenom od 10.314€ pozicionira se kao budget opcija s značajnim tržišnim prisustvom. Njemačka premium trojka pokazuje inverzni obrazac: Mercedes-Benz (12.860 vozila, 24.636€), BMW (10.664 vozila, 22.693€) i Audi (10.565 vozila, 22.854€) postižu umjerene tržišne udjele ali najviše prosječne cijene, što potvrđuje strategiju premium pozicioniranja s fokusom na profitabilnost umjesto volumena.

Toyota (6.699 vozila, 12.530€), Škoda (6.188 vozila, 14.285€) i Hyundai (4.774 vozila, 12.728€) zauzimaju nižu polovinu tržišta s value-for-money pristupom, kombinirajući pristupačne cijene s umjerenim volumenima. Ova analiza ilustrira temeljnu dilemu automobilske industrije između strategije visokog volumena/niskih marži nasuprot niskog volumena/visokih marži.

7.6.2 Geografska distribucija tipova mjenjača

Stacked bar chart prikazuje preferencije tipova mjenjača po zemljama proizvođača kroz apsolutne brojeve vozila.

Tip mjenjača po zemlji proizvođača



Slika 14: Distribucija tipova mjenjača po zemlji proizvođača

Stacked bar chart analiza otkriva karakteristike proizvodnje različitih zemalja zastupljenih na promatranom tržištu. Njemački proizvođači dominiraju ukupnim volumenom s približno 49.000 vozila, pri čemu ručni mjenjači čine značajan udio (17.478), praćeni semi-automatskim sustavima i automatskim mjenjačima. Ova distribucija odražava njemačku tradiciju inženjerske preciznosti u proizvodnji različitih tipova mjenjača.

Američki proizvođači (18.000 vozila) i britanski proizvođači (13.000 vozila) pokazuju sličan obrazac u proizvodnji s dominacijom ručnih mjenjača, što odražava prilagodbu ponude preferencama kupaca promatranog tržišta. Azijski proizvođači iz Japana (6.000), Češke Republike (6.000) i Južne Koreje (5.000) također se fokusiraju na ručne mjenjače, ali s većim udjelom automatskih sustava što ukazuje na njihovu proizvodnu specijalizaciju i tehnološku orijentaciju.

Zanimljivo je prisustvo semi-automatskih mjenjača prvenstveno u njemačkoj proizvodnji, što odražava inovativni pristup kombiniranja prednosti oba tipa mje-


njača. Ovo je tipično za njemačke premium proizvođače koji nastoje ponuditi optimum između performansi i udobnosti.

7.7 Distribucijska analiza

Peta skupina fokusira se na statističke distribucije ključnih varijabli.

7.7.1 Distribucija cijena

Histogram distribucije automobila po cijenama otkriva dominantne tržišne segmente.




Slika 15: Distribucija automobila po cijeni

Histogram jasno demonstrira izrazito desno-skrenutu (right-skewed) distribuciju s dominantnim vrhom u najnižem cjenovnom segmentu. Najveća koncentracija vozila (16.178) nalazi se u rasponu 8-13 tisuća eura, što potvrđuje dominaciju budget segmenta na promatranom tržištu. Distribucija pokazuje kontinuirani pad broja vozila s porastom cijene.

Karakteristična je pojava "dugog repa" koji se proteže do najskupljih segmenta (140k-160k€) s minimalnim brojem vozila (1-8 primjeraka), što reprezentira ekskluzivni luxury segment. Ova distribucija tipična je za sekundarna tržišta automobila gdje dominiraju rabljena vozila u pristupačnim cjenovnim kategorijama, s postupnim smanjenjem zastupljenosti prema premium i luxury segmentima.

7.7.2 Distribucija kilometraže

Slična analiza za kilometražu otkriva obrasce korištenja vozila.



Slika 16: Distribucija automobila po kilometraži

Histogram otkriva izrazito desno-skrenutu distribuciju s dominantnim vrhom u segmentu najniže kilometraže. Najveća koncentracija vozila (preko 14.000) nalazi se u rasponu 0-20.000 km, što ukazuje na značajan udio vozila s minimalnim korištenjem - vjerojatno nova ili rijetko rabljena vozila.

Distribucija pokazuje strm eksponencijalni pad s povećanjem kilometraže: od drugog vrha s približno 12.500 vozila u rasponu 20-40k km, frekvencija kontinuirano opada kroz srednje segmente (10-8k vozila u rasponu 40-80k km), sve do visokih kilometraža gdje se nalazi svega nekoliko stotina vozila.


Karakteristična je pojava "dugog repa" koji se proteže do ekstremnih kilometraža (preko 300.000 km) s minimalnim brojem vozila, što predstavlja komercijalna vozila ili intenzivno korištene automobile. Ova distribucija tipična je za tržišta koja kombiniraju nova/demonstration vozila s rabljenim vozilima različitih stupnjeva korištenja, pri čemu dominiraju vozila s niskim do umjerenim kilometražama.

7.7.3 Usporedba distribucije po tipu prijenosa

Box plot omogućuje detaljnu usporedbu distribucije cijena prema tipovima mjenjača.

Usporedba distribucije cijena po tipu prijenosa

Type (Dim Transmission)



Slika 17: Usporedba distribucije cijena po tipu prijenosa

Box plot analiza otkriva značajne razlike u cjenovnim distribucijama između tipova mjenjača. Ručni mjenjači pokazuju najnižu cjenovnu distribuciju s medijanom oko 15.000€ i kompaktnim interkvartilnim rasponom (10.000-20.000€), što potvrđuje njihovu dominaciju u budget i mainstream segmentima tržišta. Neko-liko outliera dostiže do 53.000€, predstavljajući premium sportske modele s ručnim mjenjačima.

Automatski mjenjači zauzimaju srednji segment s medijanom oko 20.000€ i širim interkvartilnim rasponom (13.000-30.000€). Značajan broj outliera proteže

se do ekstremnih vrijednosti preko 90.000€, što ukazuje na prisutnost automatskih mjenjača kroz sve tržišne segmente - od mainstream do luxury vozila.


Semi-automatski mjenjači dominiraju najvišim cjenovnim pozicioniranjem s medijanom oko 22.000€ i širim interkvartilnim rasponom (15.000-32.000€). Outlieri dosežu do 120.000€, što potvrđuje prisutnost ovog tipa mjenjača u premium i luxury segmentima, osobito kod njemačkih proizvođača koji kombiniraju sportske performanse s naprednom automatizacijom.

7.8 Analiza efikasnosti i performansi

Šesta skupina istražuje tehničke performanse i efikasnost vozila.

7.8.1 Potrošnja goriva prema starosti

Stupčasti dijagram prikazuje kako se mijenja efikasnost vozila s godinama starosti.



Slika 18: Milja po galonu (MPG) prema starosti automobila

Analiza otkriva kompleksan obrazac efikasnosti goriva kroz različite generacije vozila s jasno izraženim kategorijskim trendovima. Najstarija vozila (New - 1-5 godina) postižu umjerenu efikasnost, što odražava suvremene tehnološke standarde ali s prostorem za poboljšanje.

Skok u efikasnosti vidljiv je u kategoriji Recent vozila (5-7 godina) koja dosežu vrhunac od 49 MPG, što predstavlja optimum između tehnološke zrelosti i

regulatornih zahtjeva tog razdoblja. Mature vozila (7-12 godina) održavaju visoku efikasnost od 57-60 MPG, potvrđujući da je to razdoblje predstavljalo zlatno doba fuel-efficient tehnologija.

Starija vozila pokazuju postupan pad efikasnosti: Old kategorija (12-20 godina) varira između 41-56 MPG, dok Vintage vozila (preko 20 godina) pokazuju najnižu i najvarijabilniju efikasnost (31-41 MPG). Zanimljiv je skok na 55. godini starosti, što vjerojatno predstavlja oldtimer vozila s posebno održavanim motorima.


Ovaj trend sugerira da su vozila iz 2010-ih godina bila optimalno dizajnirana za fuel efficiency, prije nego što su novi tehnološki zahtjevi (hibridizacija, elektrifikacija) privremeno snizili prosječnu efikasnost konvencionalnih motora u najnovijim vozilima.

7.9 Fiskalna analiza

Sedma skupina analiza istražuje porezne aspekte i njihovu povezanost s karakteristikama vozila.

7.9.1 Odnos cijene i poreza po regijama

Scatter plot s trend linijama prikazuje korelaciju između cijene vozila i godišnjeg poreza po trima regijama: Aziji, Europi i Sjevernoj Americi.



Slika 19: Odnos cijene i poreza po regijama


Analiza otkriva značajne razlike u poreznim strukturama među regijama. Sjeverna Amerika pokazuje najstrmiju trend liniju, što ukazuje na najagresivniji

progresivni porezni sustav gdje porez značajno raste s cijenom vozila. Azijska tržišta pokazuju umjerenu korelaciju s koncentracijom vozila u nižem cjenovnom segmentu (do €50.000), dok Europa ima najblažu trend liniju unatoč tome što pokriva srednji i viši cjenovni segment. Trend linije jasno prikazuju da Sjeverna Amerika primjenjuje najstroži progresivni porezni sustav, dok Europa ima najmanje izraženu progresivnost poreza u odnosu na cijenu vozila.

7.9.2 Porez kao postotak cijene

Calculated field analiza prikazuje porezno opterećenje kao postotak vrijednosti vozila kroz heatmapu koja kombinira proizvođače i tipove motora.

Porez kao postotak cijene



Slika 20: Porez kao postotak cijene vozila


Heatmap analiza otkriva kompleksne obrasce poreznog opterećenja koji se kreću u rasponu od 0,00% do 1,35% vrijednosti vozila. Najviše porezno opterećenje snose Vauxhall, Toyota i Hyundai vozila na benzin. Ovo ukazuje na to da

se mass-market brendovi suočavaju s relativno višim poreznim teretom u odnosu na vrijednost vozila.

Premium njemački proizvođači pokazuju umjereniji porezni teret, što sugerira da porezni sustav favorizira skuplja vozila kroz niže relativne stope. Električni, hibridni i drugi tipovi motora pokazuju nulte ili vrlo niske stope poreza, što vjerojatno odražava porezne poticaje za ekološki prihvatljive tehnologije. Najveća porezna opterećenja nalazimo kod benzinaca i dizelaša, čime se vjerojatno želi potaknuti prelazak na čišće tehnologije.

7.9.3 Prosječni porez po zemljama proizvođača

Bar chart rangira zemlje prema prosječnom godišnjem porezu na vozila, otkrivajući varijacije u nacionalnim poreznim politikama.



Slika 21: Prosječni porez prema zemlji proizvođača

Analiza otkriva jasnu hijerarhiju poreznih opterećenja prema zemljama porijekla proizvođača na promatranom tržištu. Vozila britanskih proizvođača nose najviši prosječni porezni teret od 128€, praćena njemačkim proizvođačima s 125€. Ova razlika može odražavati diferencirane porezne stope koje lokalni porezni sustav primjenjuje na vozila različitog porijekla.

Vozila južnokorejskih (121€) i čeških proizvođača (118€) opterećena su umjerenim poreznim stopama, dok američki proizvođači uživaju nešto povoljniji tretman s prosječnim porezom od 114€. Japanski proizvođači imaju najniži prosječni porezni teret od 96€, što može ukazivati na preferencijalnu poreznu politiku prema vozilima iz te zemlje.


Ove varijacije u poreznom opterećenju prema zemlji porijekla proizvođača stvaraju različite konkurentne pozicije na tržištu, gdje vozila japanskih proizvođača uživaju poreznu prednost koja može utjecati na njihovu cjenovnu konkurentnost i tržišni udio.

7.10 Kombinirana analiza dimenzija

Završna analiza kombinira dimenzije za sveobuhvatan uvid u tržišne dinamike.

7.10.1 Multi-dimenzijska analiza starosti

Kombinirana analiza poreza i kilometraže prema kategorijama starosti vozila.



Slika 22: Srednja vrijednost poreza i kilometraže po godinama starosti

Kombinirana vizualizacija otkriva fascinantno inverzni odnos između starosti vozila, poreza i kilometraže kroz životni ciklus automobila. Analiza demonstrira kako se ove tri ključne dimenzije međusobno utječu kroz različite faze korištenja vozila.

Faza novijih vozila (0-15 godina): Vozila u ovoj kategoriji pokazuju relativno nizak prosječni porez (50-200€ godišnje) uz umjerenu kilometražu (20.000-

40.000 km). Ova faza karakterizirana je početnim razdobljem korištenja gdje vozila još uvijek zadržavaju visoku vrijednost i relativno nisko porezno opterećenje.

Faza zrelih vozila (15-25 godina): Uočava se dramatičan porast prosječnog poreza koji dostiže vrhunac oko 310€ u 24. godini starosti, dok kilometraža postupno raste prema 90.000 km. Ovaj fenomen ukazuje na to da starija vozila, unatoč manjoj tržišnoj vrijednosti, mogu nositi veći porezni teret - vjerojatno zbog poreznih politika koje penaliziraju starije, manje ekološki prihvatljive motore.

Faza vintage vozila (25+ godina): Nakon 25. godine starosti uočava se nagao pad prosječnog poreza (s 310€ na oko 80€), što sugerira postojanje poreznih olakšica za oldtimer vozila. Kilometraža u ovoj fazi pokazuje veliku varijabilnost, od minimalnih vrijednosti kod kolekcijskih vozila do preko 180.000 km kod aktivno korištenih klasika.

Graf nam otkriva da porast poreza generalno prati povećanje kilometraže koje raste s godinama starosti, s izuzetkom vintage vozila kod kojih kilometraža ne prati visoke porezne stope. Ovo se može objasniti time da su neka od vintage vozila bila aktivno vožena tijekom godina, dok su druga očuvana kao kolekcionarski primjerci s minimalnom upotrebom.

Na ovom grafu demonstrirane su napredne OLAP mogućnosti kroz kombiniranje više mjera i dimenzija, omogućujući holistički pogled na životni ciklus vozila i pružajući vrijedne uvide za optimizaciju poreznih politika, procjenu vrijednosti vozila i razumijevanje obrazaca korištenja kroz različite generacije automobila.

8 Zaključak

Ovaj projekt predstavlja sveobuhvatan prikaz procesa transformacije sirovih podataka u poslovnu inteligenciju kroz implementaciju moderne arhitekture skladišta podataka. Kroz praktičan rad s automotivnim skupom podataka, uspješno je demonstrirano kako se tradicionalni pristup rukovanja podacima može unaprijediti korištenjem naprednih tehnologija i metodologija.

Počevši od temeljite eksplorativne analize podataka, identificirane su ključne karakteristike skupa podataka. Analiza je otkrila uvide o distribuciji cijena vozila, popularnim markama i modelima, te regionalnim razlikama u automobilskom tržištu. Ustvrdeno je kako je skup podatakata čist, s niti jednom nedostajućom vrijednošću, što je olakšalo daljnju obradu i analizu. Skup je ipak trebalo prošiti dodatnim atributima kako bi se obogatila analiza, što je uključivalo dodavanje geografskih i vremenskih dimenzija.

Razvoj relacijskog modela bio je važni korak u strukturiranju podataka. Kroz proces normalizacije, transformiran je denormalizirani skup u optimalnu relacijsku strukturu s jedanaest tablica koje eliminiraju redundanciju i osiguravaju integritet podataka. Implementacija u MySQL-u s pravilno definiranim ključevima i ograničenjima postavila je čvrste temelje za daljnji rad.

Prelazak na dimenzijski model označio je promjenu paradigme u pristupu analizi podataka. Zvezdasta shema s centralnom Fact tablicom i devet dimenzijskih tablica omogućila je efikasne upite i OLAP analizu. Ova arhitektura nije samo poboljšala performanse upita, već je i omogućila intuitivniju navigaciju kroz podatke za krajnje korisnike.

ETL proces, implementiran koristeći Apache Spark, čini okosnicu projekta. Automatizacija izvlačenja podataka iz relacijske baze, njihova transformacija i učitavanje u dimenzijski model osigurava svježinu i točnost podataka u skladištu. Spark-ova distribuirana arhitektura omogućava skaliranje prema rastućim potrebama organizacije. Također je simulirano punjenje skladišta iz više izvora (CSV datoteka i baza) podataka.

OLAP analiza demonstrirala je pravu snagu implementiranog rješenja. Kroz različite scenarije analize - od jednostavnih agregacija do složenih vremenskih trendova i geografskih usporedbi - pokazali smo kako skladište podataka omogućava brzu i fleksibilnu analizu velikih količina podataka. Mogućnost filtriranja, grupiranja i agregiranja podataka po različitim dimenzijama pruža neprocjenjive uvide za poslovno odlučivanje.

Tehnička implementacija pokazala je snagu moderne big data arhitekture. Kombinacija MySQL-a, Apache Spark-a i Python-a za koordinaciju procesa predstavlja robustan i skalabilan ekosustav.

Iz perspektive poslovne vrijednosti, ovaj projekt demonstrira kako tehnički napredak direktno utječe na kvalitetu poslovnih odluka. Mogućnost brzog pristupa točnim podacima, fleksibilna analiza trendova i mogućnost predviđanja budućih kretanja predstavljaju ključne prednosti u konkurentnom poslovnom okruženju.

Gledajući unaprijed, implementirani sustav postavlja temelje za daljnje proširenje. Mogućnosti uključuju integraciju dodatnih izvora podataka, implementaciju strojnog učenja za prediktivnu analizu, te razvoj interaktivnih dashboard-a

za vizualizaciju rezultata.

Ovaj projekt uspješno je ostvario postavljene ciljeve, demonstrirajući kako se teorijska znanja o skladištima podataka mogu pretvoriti u praktična rješenja koja donose mjerljivu vrijednost. Kombinacija temeljitog pristupa, moderne tehnologije i fokusa na poslovne potrebe rezultirala je sustavom koji ne samo da rješava trenutne izazove, već i postavlja temelje za buduća proširenja i inovaciju.

Literatura

- [1] N. Silva, J. Barros, M. Y. Santos, C. Costa, and P. Cortez. Advancing Logistics 4.0 with the Implementation of a Big Data Warehouse: A Demonstration Case for the Automotive Industry. *Electronics*, 10(18):2221, 2021. [Na internetu]. Dostupno: <https://www.mdpi.com/2079-9292/10/18/2221> [pristupano 29. kolovoza 2025.].
- [2] G. Garani, A. Chernov, and I. Savvas. A Data Warehouse Approach for Business Intelligence. In *2019 IEEE 28th International Conference on Enabling Technologies: Infrastructure for Collaborative Enterprises (WETICE)*, pages 70–75, 2019. [Na internetu]. Dostupno: <https://ieeexplore.ieee.org/document/8795395> [pristupano 29. kolovoza 2025.].
- [3] P. Nima. Data Warehousing and Business Intelligence Project on Car Insights in the United Kingdom. ResearchGate, 2018. [Na internetu]. Dostupno: <https://www.researchgate.net/publication/330837638> [pristupano 29. kolovoza 2025.].
- [4] B. Leka, D. Leka, and B. Baraku. Driving Operational Excellence: Business Intelligence in the Car Parts Industry. *WSEAS Transactions on Business and Economics*, 22:356–367, 2025. [Na internetu]. Dostupno: <https://www.wseas.com/journals/bae/2025/a505118-356.pdf> [pristupano 29. kolovoza 2025.].
- [5] Meruvu Likith. 90,000+ Cars Data From 1970 to 2024. Kaggle, 2022. [Na internetu]. Dostupno: <https://www.kaggle.com/datasets/meruvulikith/90000-cars-data-from-1970-to-2024> [pristupano 29. kolovoza 2025.].
- [6] M. Komorowski, D. C. Marshall, J. D. Saliccioli, and Y. Crutain. Exploratory Data Analysis. In *Secondary Analysis of Electronic Health Records*, pages 185–203. Springer, 2016. [Na internetu]. Dostupno: https://link.springer.com/chapter/10.1007/978-3-319-43742-2_15 [pristupano 29. kolovoza 2025.].
- [7] N. Ekbote and P. Dhanshetti. Techniques of Exploratory Data Analysis. *Madhya Pradesh Journal of Social Sciences*, 28(2):45–58, 2023. [Na internetu]. Dostupno: <https://www.researchgate.net/publication/374674185> [pristupano 29. kolovoza 2025.].
- [8] Z. Wu and Z. Wu. Exploration, Visualization, and Preprocessing of High-Dimensional Data. In *Statistical Methods in Molecular Biology*, pages 163–177. Springer, 2009. [Na internetu]. Dostupno: https://link.springer.com/protocol/10.1007/978-1-60761-580-4_8 [pristupano 29. kolovoza 2025.].
- [9] R. Elmasri and S. B. Navathe. *Fundamentals of Database Systems*. Pearson, 7th edition, 2017. [Na internetu]. Dostupno: <https://www.pearson.com/us/higher-education/program/>

[Elmasri-Fundamentals-of-Database-Systems-7th-Edition/PGM189052.html](#) [pristupano 29. kolovoza 2025.].

- [10] R. Kimball and M. Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. Wiley, 3rd edition, 2013. [Na internetu]. Dostupno: <https://www.wiley.com/en-us/The+Data+Warehouse+Toolkit%3A+The+Definitive+Guide+to+Dimensional+Modeling%2C+3rd+Edition-p-9781118530801> [pristupano 29. kolovoza 2025.].
- [11] M. Zaharia, R. S. Xin, P. Wendell, T. Das, M. Armbrust, A. Dave, X. Meng, J. Rosen, S. Venkataraman, M. J. Franklin, A. Ghodsi, J. Gonzalez, S. Shenker, and I. Stoica. Apache Spark: A Unified Engine for Big Data Processing. In *Communications of the ACM*, volume 59, pages 56–65, 2016. [Na internetu]. Dostupno: <https://dl.acm.org/doi/10.1145/2934664> [pristupano 29. kolovoza 2025.].
- [12] S. Chaudhuri, U. Dayal, and V. Narasayya. An Overview of Business Intelligence Technology. *Communications of the ACM*, 54(8):88–98, 2011. [Na internetu]. Dostupno: <https://dl.acm.org/doi/10.1145/1978542.1978562> [pristupano 29. kolovoza 2025.].
- [13] M. Matošić. Sustavi poslovne inteligencije. Završni rad, Sveučilište Jurja Dobrile u Puli, 2015. [Na internetu]. Dostupno: <https://repozitorij.unipu.hr/islandora/object/unipu%3A203/datastream/PDF/view> [pristupano 6. rujna 2025.].
- [14] S. Chaudhuri and U. Dayal. An Overview of Data Warehousing and OLAP Technology. *ACM SIGMOD Record*, 26(1):65–74, 1997. [Na internetu]. Dostupno: <https://dl.acm.org/doi/10.1145/248603.248616> [pristupano 6. rujna 2025.].
- [15] D. Murray. *Tableau Your Data!: Fast and Easy Visual Analysis with Tableau Software*. Wiley, 2013. [Na internetu]. Dostupno: <https://www.wiley.com/en-us/Tableau+Your+Data%21%3A+Fast+and+Easy+Visual+Analysis+with+Tableau+Software-p-9781118612040> [pristupano 6. rujna 2025.].

Popis slika

1	Konceptualni Entity-Relationship dijagram	12
2	Implementirani relacijski model u MySQL bazi podataka	13
3	Star schema dimenzijskog modela za analizu automobilskeg tržišta .	17
4	Prosječna cijena automobila po desetljeću i regiji	31
5	Prosječna cijena automobila po zemlji proizvođača	32
6	Prosječna cijena automobila po godini i desetljeću	33
7	Top modeli automobila prema cijeni	34
8	Odnos cijene i veličine motora po proizvođaču	35
9	Prosječna cijena automobila po proizvođaču u odnosu na tip motora	36
10	Prosječna cijena vozila po proizvođaču i modelu	37
11	Odnos starosti i kilometraže automobila	38
12	Prijeđeni kilometri po tipu motora	39
13	Udio proizvođača na tržištu i prosječna cijena automobila	40
14	Distribucija tipova mjenjača po zemlji proizvođača	42
15	Distribucija automobila po cijeni	43
16	Distribucija automobila po kilometraži	44
17	Usporedba distribucije cijena po tipu prijenosa	45
18	Milja po galonu (MPG) prema starosti automobila	46
19	Odnos cijene i poreza po regijama	47
20	Porez kao postotak cijene vozila	48
21	Prosječni porez prema zemlji proizvođača	49
22	Srednja vrijednost poreza i kilometraže po godinama starosti	50

Popis tablica

1	Struktura originalnog skupa podataka	6
---	--	---